AI MODEL BENCHMARK FOR CRT RESPONSE

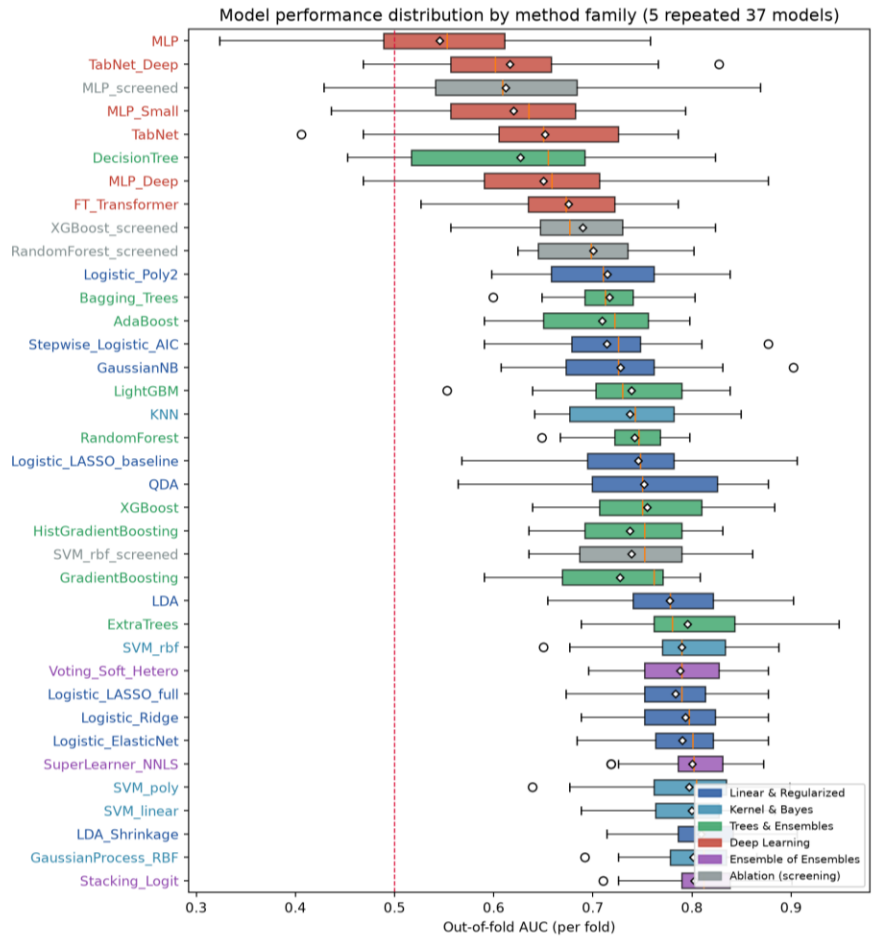
CRT 应答预测：哪种建模方案最适配？

37 种建模方案 · 六大方法族 · 三段式评测

广筛 → 嵌套调参 → 四种重采样交叉验证，全程无数据泄漏

南京医科大学第一附属医院 · 心律失常团队

汇报人：于老师 | 2026 年 10 月



真实运行产物：37 个模型的折外 AUC 分布（按方法族着色）

CONTENTS

目录

三个问题，一条主线：

为什么做 · 怎么比才公平 · 结论有多稳

01 **研究动因与数据**

编辑退修意见 · 163 例 CRT 队列 · 因变量与 28 个候选自变量

02 **评测设计：37 种方案怎么比**

六大方法族 · 三段式评测（广筛 → 嵌套调参 → 稳健性）· 多重统计检验

03 **结果与发现**

37 模型总榜 · 家族对比 · 显著性与稳健性 · SHAP 可解释性

01

SECTION 01

研究动因与数据

- 编辑退修意见：稿件缺少 AI 算法、深度学习等内容
- 沿用同一套 163 例数据，与已发表 LASSO 结果直接可比
- 建模任务明确：response 为因变量，其余 28 列为候选自变量

编辑的退修意见

> 于老师，我看了，这个稿件**没有涉及 AI 算法、深度学习、影像智能重建或分析、大数据挖掘**这些 ITM 明确列出的方向。它更像是一篇传统的影像生物标志物研究，偏临床预测模型，而不是智能转化医学的范畴，您看看能不能增加这方面的内容。
>
> —— ITM 编辑退修意见（2026 年 10 月）

判断 1 **这是方向性要求**

不是文字润色，而是必须真正补上 AI 建模内容，否则无法进入 ITM 的收稿范围。

判断 2 **同一套数据才可比**

沿用已发表 LASSO 研究的 163 例队列与同一组变量，新旧结果才有可比性。

判断 3 **一次投入，两篇产出**

基准对比支撑新 article，方法学梳理同时喂给综述。

本页落点：要做的不是"再加一段 AI"，而是回答——这批数据到底适配哪一种 AI 模型?

一份队列，一个明确的预测任务

数据来自南京医科大学第一附属医院 2010–2020 年药物难治性心衰 CRT 患者，与已发表论文（Jiang et al., QIMS 2025）完全同源。

全部变量均为数值型，无需复杂特征工程即可直接进入统一对比框架。

163
例患者

29
列变量

93:70
应答 : 不应答

变量类别	具体变量	类型
人口学 / 合并症	Gender_male, Age, DCM, Hypertension, Diabetes	连续 + 二分类
心电图 / 心律	QRSd_ms, NS_VT	连续 + 二分类
化验 / 功能分级	NT_proBNP（有序 1–5），NYHA（2–4）	有序分类
超声心动图	EDV, ESV, LVEDD, LVESD, LVEF_Echo	连续
SPECT 影像 / 相位	LVEF_SPECT, Rest_Scar_Burden, PSD / PBW, match, lead_in_scar	连续 + 二分类

- 数据质量备注：Age 有 1 例取值 165（疑录入错误，保留原值以与已发表队列一致）；全表 0 缺失、无重复行。

02

SECTION 02

对比设计与方法

- 37 个候选模型：六大方法族，从正则线性模型到深度学习与集成之集成
- 嵌套重复分层交叉验证：外层 5 折 × 5 次重复，内层 3 折调参
- 预处理与调参只发生在训练折内，全程杜绝数据泄漏

方法全景：37 种建模方案，六大方法族

线性 / 正则化 10 个

LASSO · Ridge · ElasticNet · 逐步AIC · LDA/QDA · 朴素贝叶斯 · 多项式展开

核方法 / 贝叶斯 5 个

SVM（线性/多项式/RBF） · 高斯过程 · KNN

树模型与集成 9 个

决策树 · RF · ExtraTrees · GBDT · HistGB · XGBoost · LightGBM · AdaBoost · Bagging

深度学习 6 个

MLP（小/中/深） · TabNet · TabNet-Deep · FT-Transformer（自研实现）

集成之集成 3 个

软投票 · Stacking（折内元特征，天生无泄漏） · Super Learner（非负权重）

筛选消融 4 个

SVM/XGBoost/MLP/RF 的"单变量筛选版"，用于量化特征筛选的得失

含已发表 LASSO 基线

与 Jiang et al. QIMS 2025 完全同源的列线图方法，作为参照系

全部 37 个模型使用同一套数据划分、同一种预处理管道、同一随机种子 —— 唯一的变量是"建模方法本身"

三段式评测：先广筛，再精调，最后交叉验证稳健性

Stage A · 全模型广筛

37 模型 × 5 折 × 5 次重复分层 CV

固定超参，同一套划分公平排队

产出：总榜 / 家族对比 / Friedman 检验

→

Stage B · 嵌套调参

总榜前 8 名进入内层 3 折网格搜索

调参只发生在训练折内，无泄漏

产出：最终排名 / 三重显著性比较

→

Stage C · 稳健性确认

留一法 LOOCV · 100 次蒙特卡洛留出

Bootstrap 乐观度校正 · 5 种子重复 CV

产出：结论在 4 种重采样下是否一致

三重显著性口径

① Friedman 总括 + Nemenyi 事后检验（37 模型整体排序，Demšar 2006）

② 折级配对 Wilcoxon + Holm 校正（同一外层折配对）

③ 池化折外预测 DeLong 检验（患者层面、阈值无关）

指标覆盖四个维度

区分度：AUC · 平均精确率 · MCC

校准度：Brier · 校准斜率/截距 · ICI

阈值点：Youden 敏感性/特异性 · PPV · NPV

临床效用：决策曲线净收益（5%–95% 阈值网格均值）

防泄漏三件套：预处理内嵌管道 · 单变量筛选只在训练折 · 调参在外层 CV 内部再嵌套一层

03

SECTION 03

结果与发现

- 37 模型总榜：LDA_Shrinkage 以 0.809 居首，已发表基线列第 19 位
- Friedman + Nemenyi：5 个模型显著优于基线，4 个深度模型显著更差
- SHAP 可解释性：与已发表的临床叙事一致

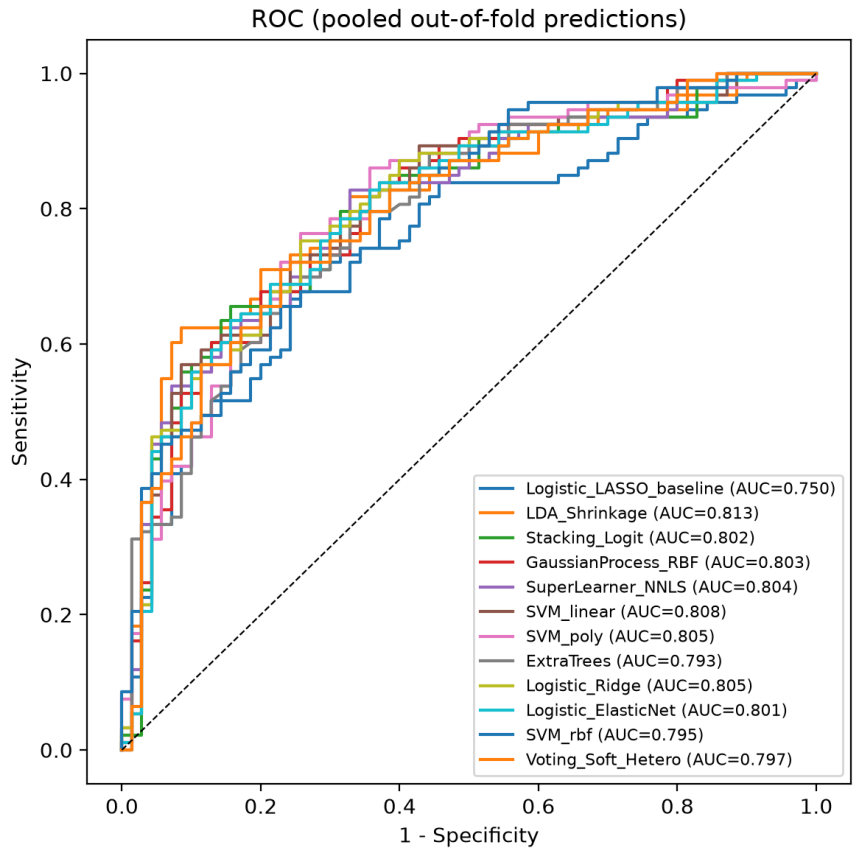
37 模型总榜：收缩判别分析居首，深度学习垫底

0.809

LDA_Shrinkage 折均 AUC

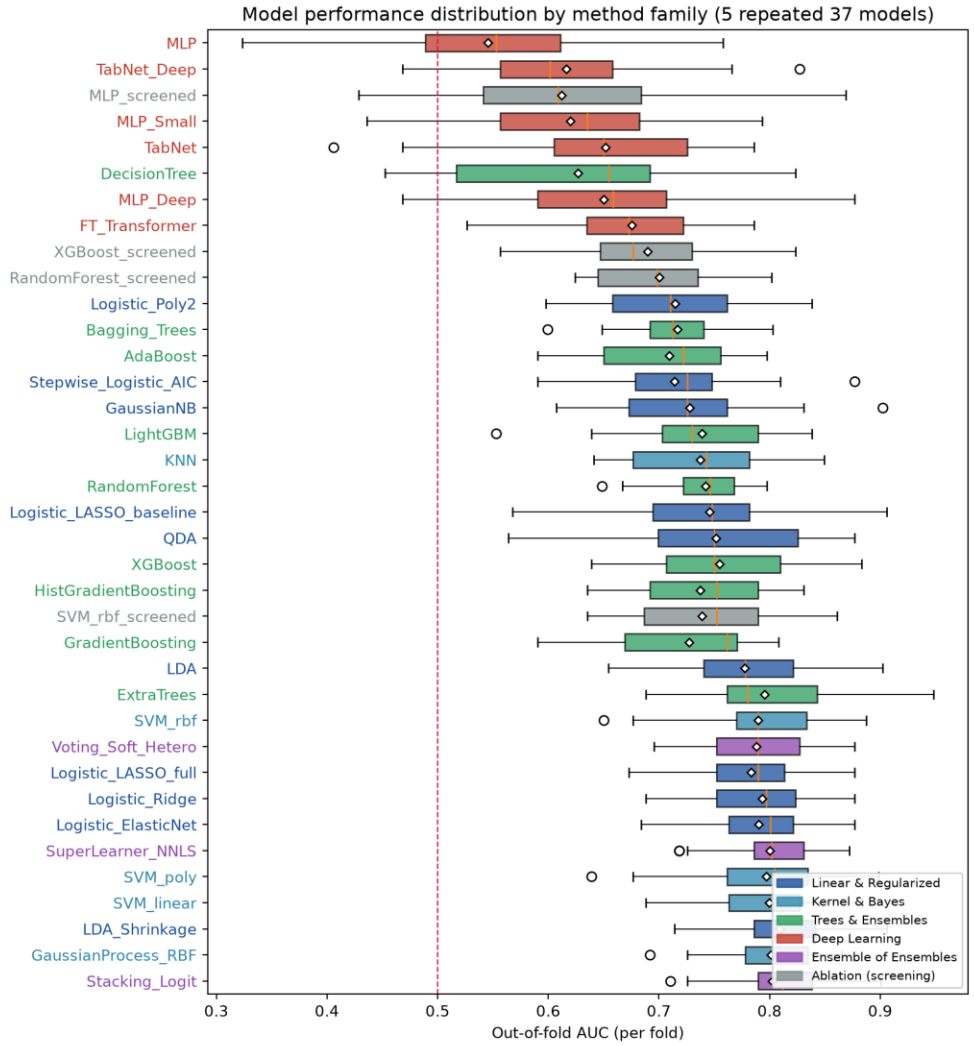
25 个外层折均值 ± SD 0.047

#	模型	方法族	折均 AUC
1	**LDA_Shrinkage**	线性/正则	**0.809**
2	Stacking_Logit	集成之集成	0.802
3	GaussianProcess_RBF	核方法/贝叶斯	0.801
4	SuperLearner_NNLS	集成之集成	0.800
5	SVM_linear	核方法/贝叶斯	0.800
6	SVM_poly	核方法/贝叶斯	0.797
7	ExtraTrees	树模型与集成	0.795
19	LASSO 基线（已发表）	线性/正则	0.746
33	TabNet_Deep	深度学习	0.616
37	MLP	深度学习	0.546



前 12 名折外预测合并 ROC · 已发表 LASSO 基线折均 0.746，列第 19 / 37 位

按方法族看：经典方法全面领先，深度学习整体掉队



方法族	模型数	族均 AUC	族内最佳
集成之集成	3	**0.797**	Stacking 0.802
核方法/贝叶斯	5	0.785	GP 0.801
线性/正则化	10	0.761	LDA_S 0.809
树模型与集成	9	0.728	ExtraTrees 0.795
筛选消融	4	0.685	SVM_rbf_s 0.739
深度学习	6	**0.627**	FT-T 0.676

读图要点　箱体为每个模型 25 个外层折的 AUC 分布（菱形=均值）。

领先梯队由**集成之集成 + 核方法 + 收缩判别**构成；

红色（深度学习）全部位于基线（0.746）以下，与文献中"小样本表格数据深度学习无优势"的系统证据一致。

消融发现：单变量筛选对 SVM/RF 无增益（0.790→0.739 / 0.742→0.700）——强正则模型自己会处理弱特征

这些差异是统计显著的，且用三种口径交叉验证

Friedman 总括检验 $\chi^2 = 489.3$，$p = 6.8e\text{-}81$（37 模型 × 25 区组）→ 模型间差异整体存在

Nemenyi vs 基线（Holm 校正）	平均秩	基线平均秩 18.7	p (Holm)
LDA_Shrinkage	6.8	**显著更优**	0.0035
Stacking_Logit	7.5	**显著更优**	0.0087
SuperLearner_NNLS	8.1	**显著更优**	0.017
GaussianProcess_RBF	8.2	**显著更优**	0.019
SVM_linear	8.5	**显著更优**	0.025
MLP（最差）	33.5	**显著更差**	<0.001
TabNet_Deep / MLP_Small 等	30–31	**显著更差**	0.001–0.005

临界差 CD = 16.67：与基线平均秩相差超过 CD 的模型才判定显著。共 5 个模型显著更优，5 个模型（含 4 个深度模型）显著更差。

口径 ②：折级 Wilcoxon + Holm

Stage B 嵌套调参后，前 8 名全部显著优于基线：

ΔAUC = +0.037 ~ +0.057，

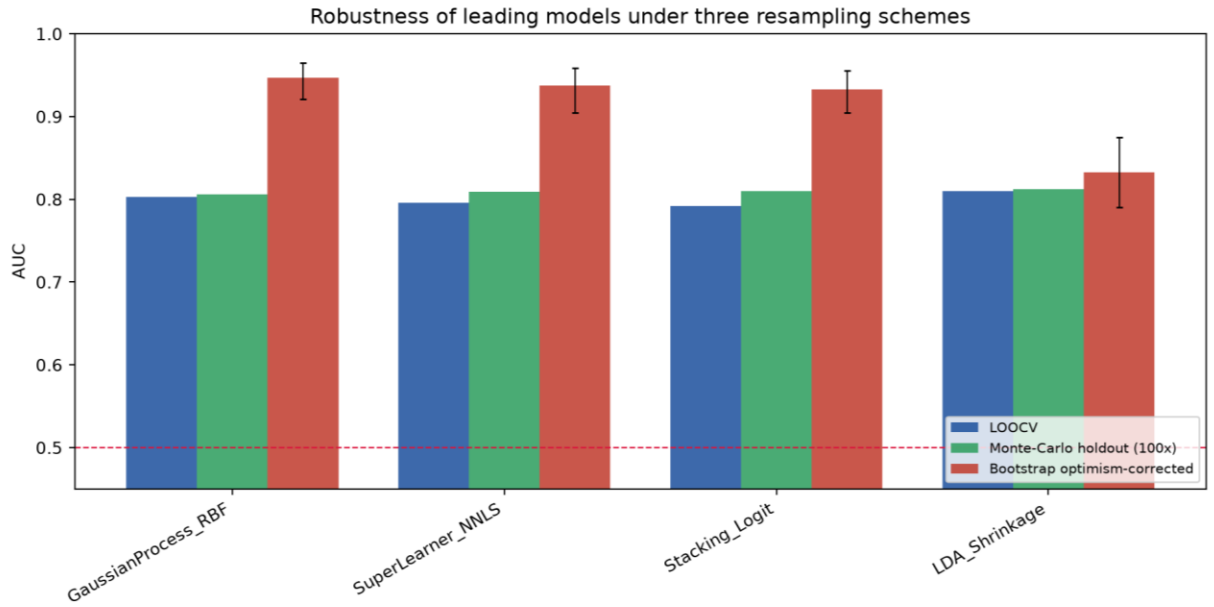
Holm 校正 p = 0.0036 ~ 0.049。

口径 ③：患者层面 DeLong（诚实披露）

池化折外预测上 ΔAUC = 0.041 ~ 0.054，但 Holm 校正后 p = 0.12 ~ 0.26，未达显著。三种口径里它最保守——论文写作时按此口径陈述，避免过度声称。

校准补充：SuperLearner 斜率 1.00 / 截距 0.01（接近理想）；LDA_Shrinkage 斜率 0.63 偏保守，部署前宜再校准。

换个划分方式重跑，结论不变吗？——四种重采样交叉确认



四种重采样方案下的 AUC：LOOCV（留一法）· 蒙特卡洛 100 次留出 · Bootstrap 乐观度校正（200 次自抽样）

模型	LOO	蒙特卡洛	5 种子均值	种子间 SD
LDA_Shrinkage	0.810	0.812	**0.810**	0.006
Stacking_Logit	0.792	0.810	0.803	0.006
GaussianProcess_RBF	0.803	0.806	0.796	0.007
SuperLearner_NNLS	0.796	0.809	0.801	0.009

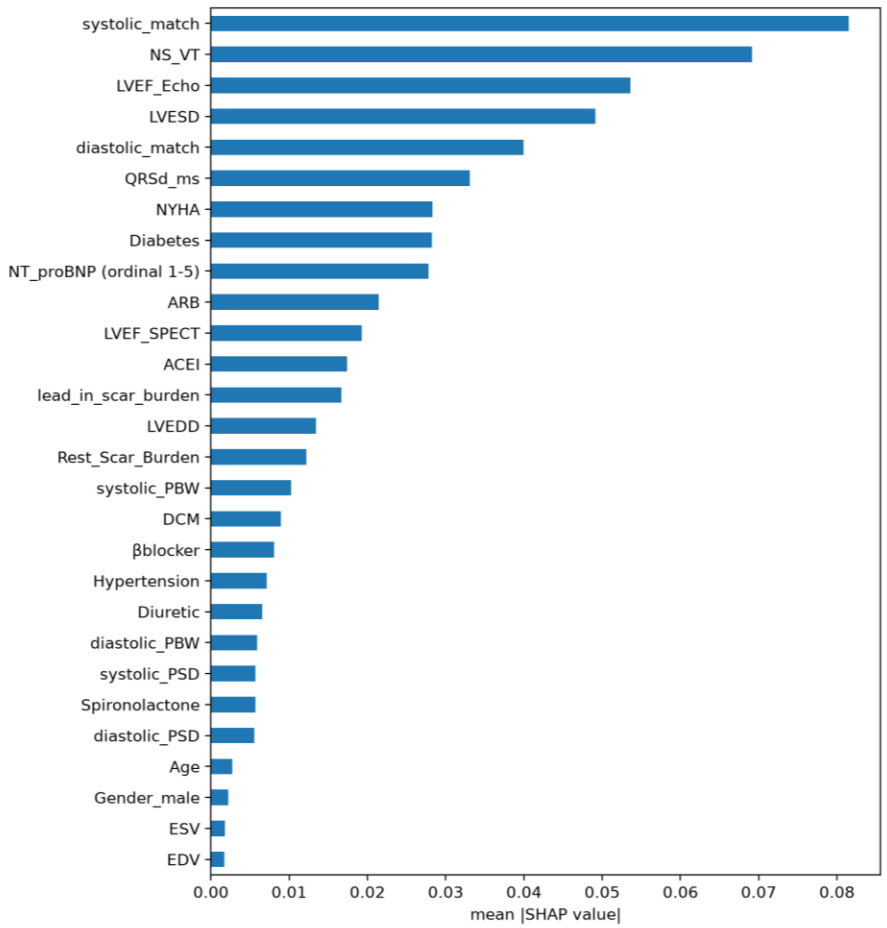
LDA_Shrinkage 在 5 个随机种子下全部排名第一

LOO 与蒙特卡洛口径下，四个领先模型全部落在 0.79–0.81 的窄带内——排名对数据划分方式不敏感。

Bootstrap 校正揭示过拟合风险：GP / Stacking 的表观 AUC 高达 0.98，校正后仍虚高（0.93–0.95）；而 LDA_Shrinkage 三口径最一致（0.81 / 0.81 / 0.83）——最"诚实"的模型。

结论排序不是种子运气：LDA_Shrinkage 种子间 SD 仅 0.006，times_best = 5/5。

模型为什么这样选：SHAP 可解释性



最优模型（LDA_Shrinkage）SHAP 重要性，KernelExplainer，全部 28 个特征

重要性前 5 的特征

1. **LVESD** 左室收缩末内径 —— 左室重构程度
2. **LVEF_Echo** 超声左室射血分数 —— 收缩功能
3. **NT_proBNP** 神经激素水平（有序 1–5 分级）
4. **QRSd_ms** QRS 时程 —— 电学失同步
5. **NYHA** 心功能分级

与已发表论文的临床叙事**完全一致**：左室重构更重、神经激素水平更高、电学失同步更明显的患者更难获得应答。模型不是在"背数据"，而是在复述临床直觉。

CONCLUSION

小样本临床数据上，适配的方案是收缩判别与强正则方法，不是更深的网络。

- 37 种方案系统评测：LDA_Shrinkage 0.809 居首，5 个模型经 Nemenyi 检验显著优于已发表 LASSO 基线（0.746，第 19/37 位）
- 深度学习六种变体**全部低于基线**（族均 0.627），4 种经检验显著更差——回应编辑"补 AI"的同时给出诚实的负结果
- 结论经 4 种重采样 + 5 种随机种子交叉确认；SHAP 前列特征（systolic_match、NS_VT、LVEF_Echo、LVESD）与临床叙事一致

下一步　① 以 LDA_Shrinkage 为核心撰写对比论文　② 前瞻性外部队列验证　③ 部署前对最优模型做概率再校准

完整结果：outputs/benchmark/report.md（含可复用 Methods 文本与全部数据表）