AI MODEL BENCHMARK FOR CRT RESPONSE

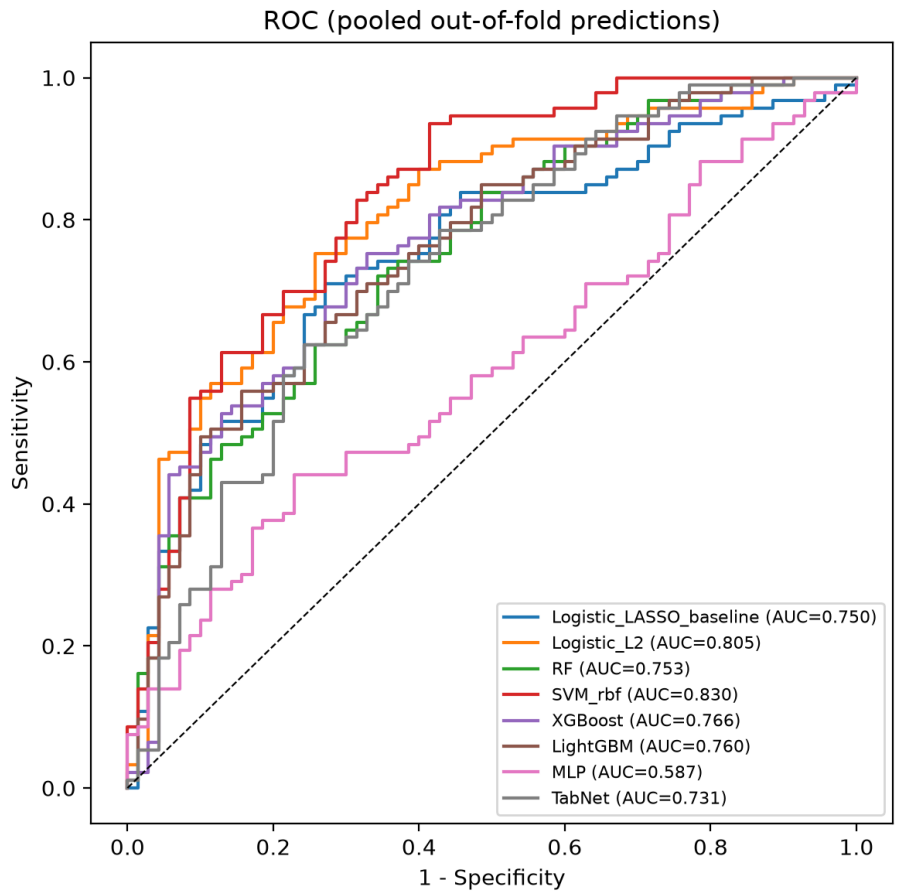
CRT 应答预测：哪种 AI 模型最适配？

8 种模型 · 嵌套重复分层交叉验证 · 全程无数据泄漏

用同一套 163 例数据，给出一个可复现的答案

南京医科大学第一附属医院 · 心律失常团队

汇报人：于老师 | 2026 年 10 月



真实运行产物：8 模型折外预测合并 ROC（跨 5 次重复平均）

CONTENTS

目录

三个问题，一条主线：

为什么做 · 怎么比 · 结果如何

01 **研究动因与数据**

编辑退修意见 · 163 例 CRT 队列 · 因变量与 28 个候选自变量

02 **对比设计与方法**

8 个候选模型 · 嵌套重复分层交叉验证 · 预处理内嵌无泄漏

03 **结果与发现**

AUC 排行 · 配对显著性检验 · SHAP 可解释性 · 结论与下一步

01

SECTION 01

研究动因与数据

- 编辑退修意见：稿件缺少 AI 算法、深度学习等内容
- 沿用同一套 163 例数据，与已发表 LASSO 结果直接可比
- 建模任务明确：response 为因变量，其余 28 列为候选自变量

编辑的退修意见

> 于老师，我看了，这个稿件**没有涉及 AI 算法、深度学习、影像智能重建或分析、大数据挖掘**这些 ITM 明确列出的方向。它更像是一篇传统的影像生物标志物研究，偏临床预测模型，而不是智能转化医学的范畴，您看看能不能增加这方面的内容。
>
> —— ITM 编辑退修意见（2026 年 10 月）

判断 1 **这是方向性要求**

不是文字润色，而是必须真正补上 AI 建模内容，否则无法进入 ITM 的收稿范围。

判断 2 **同一套数据才可比**

沿用已发表 LASSO 研究的 163 例队列与同一组变量，新旧结果才有可比性。

判断 3 **一次投入，两篇产出**

基准对比支撑新 article，方法学梳理同时喂给综述。

本页落点：要做的不是"再加一段 AI"，而是回答——这批数据到底适配哪一种 AI 模型?

一份队列，一个明确的预测任务

数据来自南京医科大学第一附属医院 2010–2020 年药物难治性心衰 CRT 患者，与已发表论文（Jiang et al., QIMS 2025）完全同源。

全部变量均为数值型，无需复杂特征工程即可直接进入统一对比框架。

163
例患者

29
列变量

93:70
应答 : 不应答

变量类别	具体变量	类型
人口学 / 合并症	Gender_male, Age, DCM, Hypertension, Diabetes	连续 + 二分类
心电图 / 心律	QRSd_ms, NS_VT	连续 + 二分类
化验 / 功能分级	NT_proBNP（有序 1–5），NYHA（2–4）	有序分类
超声心动图	EDV, ESV, LVEDD, LVESD, LVEF_Echo	连续
SPECT 影像 / 相位	LVEF_SPECT, Rest_Scar_Burden, PSD / PBW, match, lead_in_scar	连续 + 二分类

- 数据质量备注：Age 有 1 例取值 165（疑录入错误，保留原值以与已发表队列一致）；全表 0 缺失、无重复行。

02

SECTION 02

对比设计与方法

- 8 个候选模型：从正则化线性模型一直到深度学习
- 嵌套重复分层交叉验证：外层 5 折 × 5 次重复，内层 3 折调参
- 预处理与调参只发生在训练折内，全程杜绝数据泄漏

8 个候选模型与无泄漏对比设计



标准化、缺失填补与超参搜索全部只发生在训练折内 —— 预处理内嵌于建模管道，全程无数据泄漏

Logistic_LASSO 基线
已发表方法

Logistic_L2
正则化线性

随机森林 RF
bagging 集成

SVM_rbf
核方法

XGBoost
梯度提升树

LightGBM
梯度提升树

MLP 多层感知机
深度学习

TabNet
深度学习 · 注意力特征

评价指标：AUC · Brier · 校准斜率 · Youden 敏感性/特异性 · DCA 净收益 | 统计检验：配对 Wilcoxon + Holm 校正

03

SECTION 03

结果与发现

- AUC 排行：RBF 核 SVM 以 0.820 居首
- 配对显著性检验：差异不是抽样波动
- SHAP 可解释性：与已发表的临床叙事一致

最优模型：RBF 核 SVM

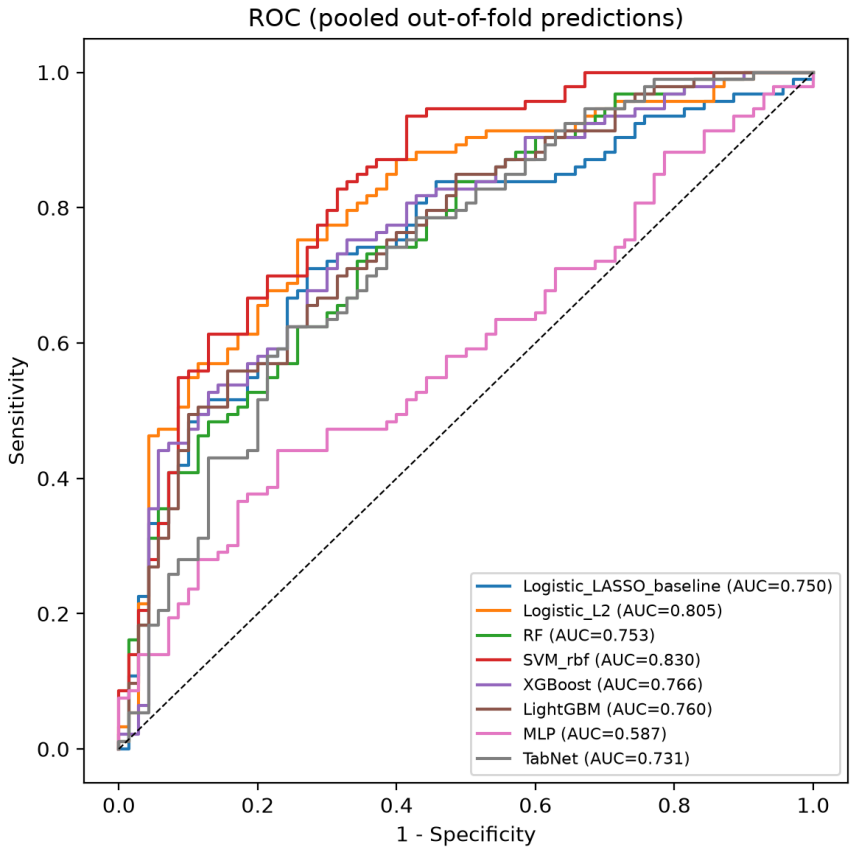
0.820

SVM_rbf 折均 AUC

25 个外层折的均值 ± SD

模型	折均 AUC	± SD
SVM_rbf	**0.820**	0.060
Logistic_L2	0.793	0.054
XGBoost	0.757	0.061
Logistic_LASSO 基线（已发表）	0.746	0.074
LightGBM	0.745	0.075
RF	0.742	0.036
TabNet	0.652	0.101
MLP	0.559	0.100

口径说明：表内为折均 AUC；右图 ROC 为折外预测合并口径（跨 5 次重复平均，SVM = 0.830）。两种口径结论一致。



8 模型折外预测合并 ROC（跨 5 次重复平均）

差异是统计显著，不是抽样波动

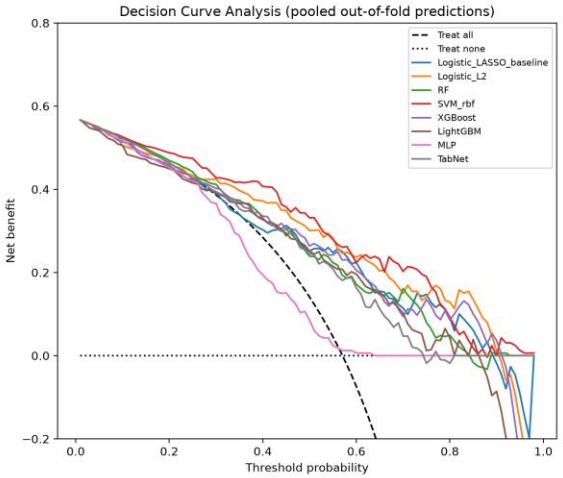
这些差异是真的吗? 配对 Wilcoxon 检验 + Holm 校正（同一外层折配对，n = 25）

模型	ΔAUC vs 基线	p (Holm)	判定
SVM_rbf	**+0.075**	3.9e-05	**显著更优**
Logistic_L2	+0.048	0.018	**显著更优**
XGBoost	+0.011	1.000	无差异
LightGBM	-0.000	1.000	无差异
RF	-0.003	1.000	无差异
TabNet	-0.094	5.1e-04	**显著更差**
MLP	-0.186	4.2e-07	**显著更差**

校准曲线同样支持这一排序：SVM 与 Logistic_L2 的预测概率贴近对角线，而 MLP 的校准明显失真——其输出不能直接当作概率使用。

DCA 临床净收益

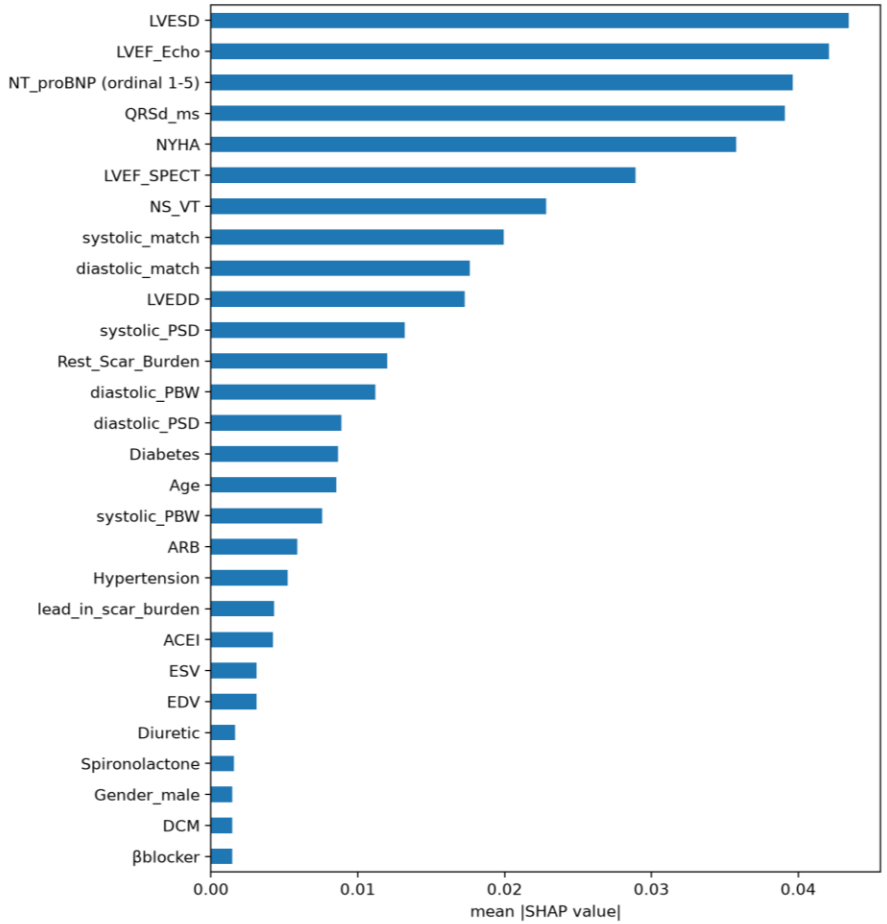
在 0.1–0.9 的全部阈值区间，SVM_rbf 的净收益曲线整体最高；MLP 甚至长期低于"全部治疗"基线——临床决策意义上同样不可用。



折外预测合并 DCA（跨 5 次重复平均）

读法：在 n = 163 的小样本上，SVM 的领先是统计显著的，深度学习的落后同样是统计显著的。

模型为什么这样选：SHAP 可解释性



最优模型（SVM_rbf）SHAP 重要性，KernelExplainer，全部 28 个特征

重要性前 5 的特征

1. **LVESD** 左室收缩末内径 —— 左室重构程度
2. **LVEF_Echo** 超声左室射血分数 —— 收缩功能
3. **NT_proBNP** 神经激素水平（有序 1–5 分级）
4. **QRSd_ms** QRS 时程 —— 电学失同步
5. **NYHA** 心功能分级

与已发表论文的临床叙事**完全一致**：左室重构更重、神经激素水平更高、电学失同步更明显的患者更难获得应答。模型不是在"背数据"，而是在复述临床直觉。

CONCLUSION

小样本临床数据上，适配的 AI 是强正则的核方法，而不是更深的网络。

- SVM_rbf 折均 AUC **0.820**，显著优于已发表 LASSO 方法（+0.075，Holm 校正 p = 3.9e-05）
- 深度学习（MLP / TabNet）**显著更差**——在本数据集、本样本量下不推荐使用
- SHAP 前列特征（LVESD、LVEF_Echo、NT_proBNP、QRSd_ms、NYHA）与临床叙事一致，支撑可解释落地

下一步 按 TRIPOD+AI 规范起草新 article：以 SVM + SHAP 为主线；方法学对比素材同步整理为综述